

BOAZ

Bigdata is Our A to Z

21-2 학기 스터디. 파이토치 마스터


4장 인공지능망



CONTENTS

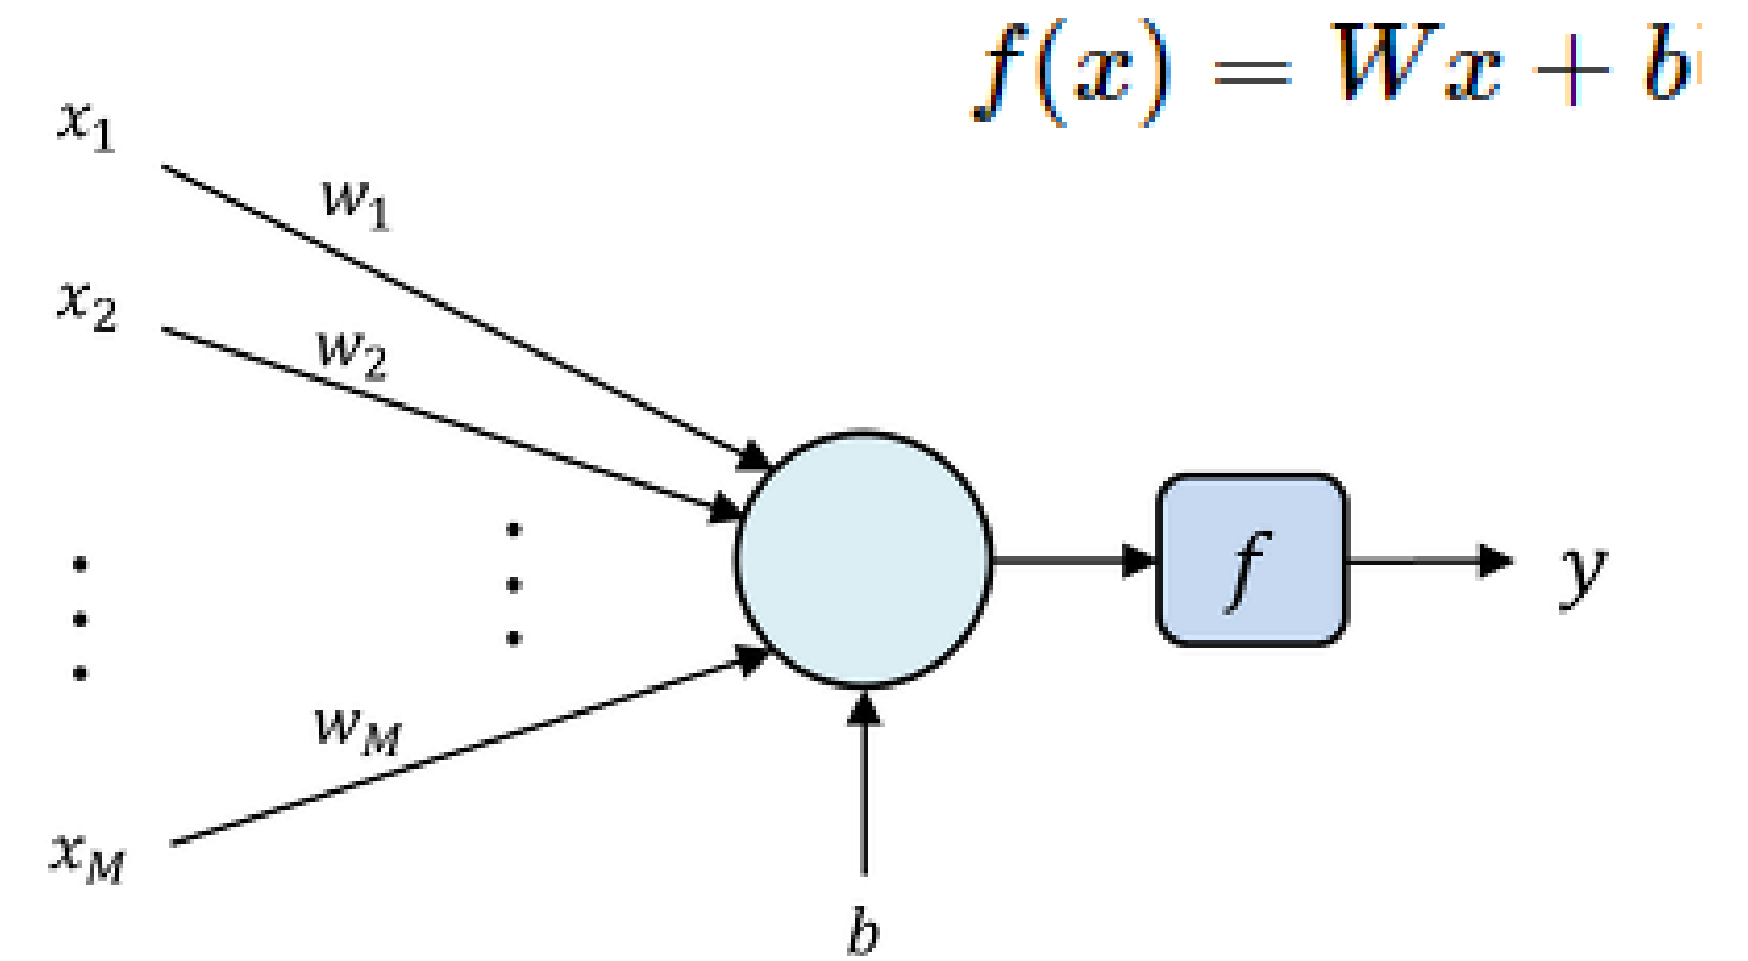
- 01 신경망이란
- 02 인공신경망 요소
- 03 전파와 역전파
- 04 모델 구현, 학습
- 05 발표 및 과제 QnA

인공 신경망 Artificial Neural Network, ANN



생물학적 신경망

여러 가지돌기dendrite들을 통해 신경세포로 들어오고 어느 정도
이상의 자극이 들어오면 이를 축삭axon을 통해 다른 세포로
전달하는 구조



인공 신경망


여러 자극 혹은 입력 x 이 들어오면 각각 가중치 w 를 곱해 더해주고 추가적으로
편차 b 도 더해준다
이렇게 다 더한 값을 활성화 함수 f 를 통해 변형하여 전달하는 단위를 인공
뉴런 y 이라고 하고 이러한 뉴런들이 모인 네트워크

인공 신경망 종류

인공신경망(ANN)은 인간의 뇌를 묘사한 기계학습 예측 모델

최근 딥러닝의 도약으로 그 성능이 재조명되고 활발하게 사용되는 중


- 퍼셉트론 Perceptron : 각 노드의 가중치 합이 0보다 크면 활성화되는 기본적인 인공신경망 알고리즘
- CNN : 시신경 구조를 모방한 인공신경망 알고리즘
- RNN : 뉴런 출력이 다시 입력으로 재귀하는 연결 구조의 인공신경망 알고리즘




입력층, 은닉층, 출력층

- 입력층 : 들어온 신호를 그대로 다음 노드에 전달하는 창구 역할
(가중합, 활성화함수 계산 X). 시스템 외부로부터 입력자료를 받아들이며 시스템으로 이들을 전송
- 출력층 : 노드의 출력이 신경망의 최종 결과값이 된다. 입력 값과 현재 시스템 상태에 기준하여 시스템 출력 값을 산출
- 은닉층 : 입력층과 출력층 사이에 있는 계층들. 신경망의 외부에서는 이 계층의 노드들에 직접 접근할 수 없다. 시스템 안쪽에 자리잡고 있으며 입력 값을 넘겨받아 그것들을 처리한 뒤 결과 산출

Hidden layer의 개수에 따라
1개) 신경망



2개 이상) 심층신경망




활성화 함수 activation function


신경망의 output을 결정하는 식

현재 뉴런의 input을 feeding하여 생성된 output이 다음 레이어로 전해지는 과정 중 역할을 수행하는 수학적 게이트

인공 신경망에서 활성화 함수는 **반드시 비선형 함수**여야 한다.



$$f(x) = Wx + b$$



활성화 함수 종류

1. 시그모이드 sigmoid 함수

결과값 0 ~ 1 완만한 곡선 형태.

보통 이진분류(

X가 매우 크거나 매우 작을 때,

함수의 Gradient(미분값, 기울기)가 거의 0이 된다는 단점이 존재한다.

따라서 **Gradient Vanishing 문제**가 발생한다.

-> Backpropagation(역전파)로 인해, 활성화 함수를 미분하는데, Sigmoid와 Tanh 함수는 미분시

Gradient값이 급격히 작아지기 때문에, 여러 번 미분시 Gradient가 사라지는 문제가 발생한다.


-> 이를 해결하기 위해 RELU 함수를 사용한다.

자세한 내용 : <https://wooono.tistory.com/209>

2. 하이퍼볼릭 탄젠트 Tanh 함수

결과값 -1 ~ 1. 수학적으로는 시그모이드를 평행이동한 것과 같다.

때문에 다음 층의



활성화 함수 종류


3. 렐루 ReLU 함수

x가 양수면 미분값이 1이고, x가 음수면 미분값이 0인 함수.

x가 음수일때 미분값이 0이라는 것이 한 가지 단점

$$R(z) = \begin{cases} z & z > 0 \\ \alpha z & z \leq 0 \end{cases}$$

$$R'(z) = \begin{cases} 1 & z > 0 \\ \alpha & z < 0 \end{cases}$$




4. 리키 렐루 Leaky RELU 함수

ReLU 단점 극복. x가 음수일 때 약간의 기울기를 갖는 함수.

잘 작동하지만 많이 사용하는 사용 X

$$f(x) = \max(0.01x, x)$$




전파, 순전파 Forward Propagation

입력값이 들어오면 여러 개의 은닉층을 순서대로 거쳐 결과값을 내는 과정

파랑 입력값 / 빨강 가중치값 / 활성화함수는 시그모이드 함수

순전파 출력값과 오차 직접 계산해보기



실제값 : 0.4

실제값 : 0.6

$$z_1 = W_1x_1 + W_2x_2 = 0.3 \times 0.1 + 0.25 \times 0.2 = 0.08$$

$$z_2 = W_3x_1 + W_4x_2 = 0.4 \times 0.1 + 0.35 \times 0.2 = 0.11$$

$$h_1 = \text{sigmoid}(z_1) = 0.51998934$$

$$h_2 = \text{sigmoid}(z_2) = 0.52747230$$

$$z_3 = W_5h_1 + W_6h_2 = 0.45 \times h_1 + 0.4 \times h_2 = 0.44498412$$

$$z_4 = W_7h_1 + W_8h_2 = 0.7 \times h_1 + 0.6 \times h_2 = 0.68047592$$

$$o_1 = \text{sigmoid}(z_3) = 0.60944600$$


$$o_2 = \text{sigmoid}(z_4) = 0.66384491$$

전파, 순전파 Forward Propagation

전파. 순전파 Forward Propagation : 입력값이 들어오면 여러 개의 은닉층을 순서대로 거쳐 결과값을 내는 과정

파랑 입력값 / 빨강 가중치값 / 활성화함수는 시그모이드 함수

순전파 출력값과 오차 직접 계산해보기



실제값 : 0.4

$$E_{o1} = \frac{1}{2} (target_{o1} - output_{o1})^2 = 0.02193381$$

$$E_{o2} = \frac{1}{2} (target_{o2} - output_{o2})^2 = 0.00203809$$

$$E_{total} = E_{o1} + E_{o2} = 0.02397190$$


실제값 : 0.6

역전파 BackPropagation

결과와 정답의 차이로 계산된 손실을 연쇄법칙을 이용하여 입력 단까지 다시 전달하는 과정

역전파 직접 해보기 1단계. 출력층에서 바로 이전의 은닉층의 가중치를 연쇄법칙을 이용하여 업데이트하는 단계

업데이트 해야 할 가중치 $W_{5,6,7,8}$ 4개



$$\frac{\partial E_{total}}{\partial W_5} = \frac{\partial E_{total}}{\partial o_1} \times \frac{\partial o_1}{\partial z_3} \times \frac{\partial z_3}{\partial W_5}$$

$$E_{total} = \frac{1}{2} (target_{o1} - output_{o1})^2 + \frac{1}{2} (target_{o2} - output_{o2})^2$$

$$\frac{\partial E_{total}}{\partial o_1} = 2 \times \frac{1}{2} (target_{o1} - output_{o1})^{2-1} \times (-1) + 0$$

$$\frac{\partial E_{total}}{\partial o_1} = -(target_{o1} - output_{o1}) = -(0.4 - 0.60944600) = 0.20944600$$

역전파 BackPropagation

$$\frac{\partial E_{total}}{\partial W_5} = \frac{\partial E_{total}}{\partial o_1} \times \frac{\partial o_1}{\partial z_3} \times \frac{\partial z_3}{\partial W_5} \quad E_{total} = \frac{1}{2} (target_{o1} - output_{o1})^2 + \frac{1}{2} (target_{o2} - output_{o2})^2$$

시그모이드 함수의 미분 $f(x) * (1-f(x)) \rightarrow \frac{\partial o_1}{\partial z_3} = o_1 \times (1 - o_1) = 0.60944600(1 - 0.60944600) = 0.23802157$

마지막 항 미분 $\rightarrow z_3 = W_5 h_1 + W_6 h_2 : \frac{\partial z_3}{\partial W_5} = h_1 = 0.51998934$


$$\frac{\partial E_{total}}{\partial W_5} = 0.20944600 \times 0.23802157 \times 0.51998934 = 0.02592286$$

학습률 0.5로 가정. 경사하강법을 통해 가중치 업데이트 $\rightarrow W_5^+ = W_5 - \alpha \frac{\partial E_{total}}{\partial W_5} = 0.45 - 0.5 \times 0.02592286 = 0.43703857$

역전파 BackPropagation

업데이트 해야 할 가중치 W1,2,3,4 4개

가중치 업데이트 완료



실제값 : 0.4

실제값 : 0.6

역전파(Back Propagation)

$$\frac{\partial E_{total}}{\partial W_1} = \frac{\partial E_{total}}{\partial h_1} \times \frac{\partial h_1}{\partial z_1} \times \frac{\partial z_1}{\partial W_1}$$

$$\frac{\partial E_{total}}{\partial h_1} = \frac{\partial E_{o1}}{\partial h_1} + \frac{\partial E_{o2}}{\partial h_1}$$

역전파 BackPropagation

Backpropagation: a simple example


$$f(x, y, z) = (x + y)z$$

e.g. $x = -2, y = 5, z = -4$


$$q = x + y \quad \frac{\partial q}{\partial x} = 1, \frac{\partial q}{\partial y} = 1$$

$$f = qz \quad \frac{\partial f}{\partial q} = z, \frac{\partial f}{\partial z} = q$$

Want: $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$



$$\frac{\partial f}{\partial f}$$



$$\frac{\partial f}{\partial x}$$

■ 모델 구현, 학습


자세한 주석 달아서 깃허브 실습코드 파일에 업로드 해두었습니다 !

`Loss.backward()` : 각 변수별 기울기 모두 계산

`nn.Sequential` 클래스 : 다양한 모듈을 담을 수 있는 일종의 리스트.

`nn.Linear`, `nn.RELU` 같은 모듈들을 인수로 받아서 순서대로 정렬해놓고 입력값이 들어오면 이 순서대로 모듈을 실행하여 결과값을 리턴. 많은 연산을 묶어서 한 번에 관리할 수 있어서 편리.

발표 및 과제 QnA



질문 있으신 분 ~

없으면 바로 과제 풀이 !

BOAZ

Thank You

